

自定义推理脚本编写手册

TSS AI 训练平台

适用基线：CPU 正式环境

版本日期：2026-08-27

本手册与平台代码同版本维护。字段、协议或页面变化时，以对应版本手册为准。

自定义推理脚本编写手册

适用平台：TSS AI 训练平台 正式可视化：CV 目标检测、CV 分类、表格分类、NLP 文本分类、通用 JSON 手册版本：2026-08-27

1. 先说结论

推理脚本的业务字段可以自定义，但不是“写什么都能自动画图”。

- 必须：脚本正常退出，并在 `OUTPUT_DIR/result.json` 写 JSON 对象；
- 推荐：使用 `tss.inference.result/v1` 标准字段；
- 标准字段匹配时，平台展示专用图片、表格、置信度和分布图；
- 未匹配时，任务仍可成功，但页面只展示通用 JSON 和文件下载；
- 历史脚本继续兼容，平台不会因新增协议批量判失败。

2. ZIP 包最小结构

```
inference-script.zip
├── infer.py
└── requirements.txt  # 可选
```

上传时填写：脚本名称、版本、运行环境、入口文件和参数 Schema。入口必须存在且不能使用绝对路径或 ...。

不要把模型、输入数据、密码、Token 或云密钥打进脚本 ZIP。

3. 平台提供的环境变量

变量	含义
MODEL_DIR	本次模型目录（只读）
INPUT_PATH	单文件或已展开的数据集输入路径
OUTPUT_DIR	本次输出目录
PARAMS_JSON	页面提交的脚本参数 JSON
TASK_ID	推理任务 ID
INPUT_MODE	SINGLE_OBJECT 或 DATASET_VERSION

脚本只读 `MODEL_DIR` 和 `INPUT_PATH`，所有新文件都写进 `OUTPUT_DIR`。

4. 最小入口

```
import json
import os
from pathlib import Path

model_dir = Path(os.environ[&quot;MODEL_DIR&quot;])
input_path = Path(os.environ[&quot;INPUT_PATH&quot;])
output_dir = Path(os.environ[&quot;OUTPUT_DIR&quot;])
params = json.loads(os.environ.get(&quot;PARAMS_JSON&quot;, &quot;{}&quot;))
output_dir.mkdir(parents=True, exist_ok=True)

# 加载模型并推理.....

result = {
    &quot;schemaVersion&quot;: &quot;tss.inference.result/v1&quot;,
    &quot;ok&quot;: True,
    &quot;view&quot;: &quot;unknown&quot;,
    &quot;taskId&quot;: os.environ.get(&quot;TASK_ID&quot;),
    &quot;inputMode&quot;: os.environ.get(&quot;INPUT_MODE&quot;),
    &quot;summary&quot;: &quot;推理完成&quot;
}
(output_dir / &quot;result.json&quot;).write_text(
    json.dumps(result, ensure_ascii=False, indent=2),
    encoding=&quot;utf-8&quot;
)
```

5. 公共结果字段

字段	类型	规则
schemaVersion	string	推荐固定为 <code>tss.inference.result/v1</code>
ok	boolean	业务结果是否生成成功
view	string	明确选择可视化类型
taskId	string/null	建议回写 <code>TASK_ID</code>
inputMode	string/null	建议回写 <code>INPUT_MODE</code>
summary	string	一句话摘要，可选
artifacts	object	相对 <code>OUTPUT_DIR</code> 的产物路径，可选
extra	object	业务自定义扩展字段，可选

自定义字段优先放入 `extra`，避免未来与公共字段重名。

6. 已正式支持的 view

view	当前效果	是否正式可用
image_detection	原图、标注图、框列表、类别、置信度	是
image_classification	预测样例、Top-K、分类指标/分布	是
table_classification	表格预测、概率和分类指标	是
text_classification	原始文本、真值、预测、置信度、Top-K、分布	是
unknown	通用 JSON 和产物下载	是，作为降级

image_segmentation、image_keypoints、image_ocr、text_generation、text_retrieval、pointcloud、multimodal 等名称已预留，但当前没有正式专用视图；使用时只保证通用降级，不应写进验收承诺。

7. CV 目标检测标准结构

```
{
  &quot;schemaVersion&quot;: &quot;tss.inference.result/v1&quot;,
  &quot;ok&quot;: true,
  &quot;view&quot;: &quot;image_detection&quot;,
  &quot;imageCount&quot;: 1,
  &quot;totalDetections&quot;: 1,
  &quot;images&quot;: [
    {
      &quot;image&quot;: &quot;input.jpg&quot;,
      &quot;width&quot;: 640,
      &quot;height&quot;: 480,
      &quot;inputPreview&quot;: {
        &quot;kind&quot;: &quot;image&quot;,
        &quot;name&quot;: &quot;input.jpg&quot;,
        &quot;path&quot;: &quot;previews/input-0.jpg&quot;
      },
      &quot;annotatedImage&quot;: &quot;annotated/input.jpg&quot;,
      &quot;labelFile&quot;: &quot;labels/input.json&quot;,
      &quot;detections&quot;: [
        {
          &quot;classId&quot;: 0,
          &quot;className&quot;: &quot;person&quot;,
          &quot;confidence&quot;: 0.93,
          &quot;bbox&quot;: {&quot;x1&quot;: 10, &quot;y1&quot;: 20, &quot;x2&quot;: 120, &quot;y2&quot;: 220}
        }
      ]
    }
  ]
}
```

规则：

- 所有路径必须相对 OUTPUT_DIR，不能写 /workspace/...；
- confidence 使用 0 ~ 1；
- bbox 固定为 x1/y1/x2/y2；
- 零目标时也要保留 detections: []、annotatedImage 和 inputPreview，页面会正常显示“0 个目标”；

- 原图预览建议最长边不超过 512 像素、JPEG/PNG、小于 20 MiB。

8. NLP 文本分类标准结构

```
{
  &quot;schemaVersion&quot;: &quot;tss.inference.result/v1&quot;,
  &quot;ok&quot;: true,
  &quot;view&quot;: &quot;text_classification&quot;,
  &quot;sampleCount&quot;: 1,
  &quot;accuracy&quot;: 1.0,
  &quot;precision&quot;: 1.0,
  &quot;recall&quot;: 1.0,
  &quot;f1&quot;: 1.0,
  &quot;predictionsPreview&quot;: [
    {
      &quot;index&quot;: 0,
      &quot;inputPreview&quot;: {
        &quot;kind&quot;: &quot;text&quot;,
        &quot;name&quot;: &quot;sample-0.txt&quot;,
        &quot;text&quot;: &quot;短文本可直接放这里&quot;,
        &quot;summary&quot;: &quot;短文本可直接放这里&quot;
      },
      &quot;label&quot;: &quot;正面&quot;,
      &quot;prediction&quot;: &quot;正面&quot;,
      &quot;confidence&quot;: 0.97,
      &quot;correct&quot;: true,
      &quot;topKRecords&quot;: [
        {&quot;label&quot;: &quot;正面&quot;, &quot;confidence&quot;: 0.97},
        {&quot;label&quot;: &quot;负面&quot;, &quot;confidence&quot;: 0.03}
      ]
    }
  ],
  &quot;labelCounts&quot;: {&quot;正面&quot;: 1},
  &quot;predictionCounts&quot;: {&quot;正面&quot;: 1},
  &quot;artifacts&quot;: {&quot;predictionsJsonl&quot;: &quot;predictions.jsonl&quot;}}
}
```

长文本不要全部塞进 `result.json`。建议：

```
{
  &quot;inputPreview&quot;: {
    &quot;kind&quot;: &quot;text&quot;,
    &quot;name&quot;: &quot;sample-12.txt&quot;,
    &quot;summary&quot;: &quot;前 120 字摘要.....&quot;,
    &quot;path&quot;: &quot;previews/text/12.txt&quot;,
    &quot;truncated&quot;: true
  }
}
```

页面按需读取文本；单个预览超过 2 MiB 时只提供下载。结果预览建议最多 50 条，完整结果写 JSONL/CSV 产物。

9. 原始输入“箱子”协议

`inputPreview` 是每条预测的统一原始输入容器：

kind	字段	页面行为
image	name、 path	缩略图，点击放大，可下载
text	name、 text/summary/path	摘要，点击弹窗，可下载
file	name、 path	文件名和下载按钮

安全要求：

- `path` 只能指向本次 `OUTPUT_DIR` 下的相对文件；
- 禁止 `..`、反斜杠、绝对路径、外部 URL 和其他用户对象路径；
- 预览失败只降级当前一条，不应让整次推理失败；
- 输入本身敏感时，不要把完整内容复制进 `result.json`。

10. 产物和错误处理

平台会上传 `OUTPUT_DIR` 下全部文件。建议至少包含：

```
OUTPUT_DIR/
├── result.json
├── predictions.jsonl
├── previews/
└── annotated/      # CV 可选
```

失败时：

1. 把便于用户理解的简短原因写到 `stdout/stderr`；
2. 让进程以非 0 退出；
3. 不把完整栈、密钥或输入隐私写入 `result.json`；
4. 不要捕获异常后强行返回成功。

如果 `result.json` 缺失，worker 会回传空对象；如果 JSON 损坏，会返回 `rawResultError`。这两种情况都无法得到正式可视化。

11. 参数 Schema

上传脚本时的参数 Schema 用于限制页面输入，例如：

```
{
  "type": "object",
  "properties": {
    "threshold": {"type": "number", "minimum": 0, "maximum": 1, "default": 0.5},
    "batchSize": {"type": "integer", "minimum": 1, "maximum": 128, "default": 8}
  },
  "additionalProperties": false
}
```

脚本仍需自行处理缺省值和类型异常，不能假设所有历史调用者都传了最新字段。

12. 上线前最小验收

- 单文件和数据集两种输入至少验证一种正式路径；
- `result.json` 是 UTF-8 JSON 对象；
- `view` 与字段结构一致；
- 图片、短文本、长文本和普通文件按协议降级；
- 零检测结果不会显示“未识别”；
- 所有路径位于 `OUTPUT_DIR` 且无越权；

- 结果、日志和产物能由浏览器下载;
- 错误参数、缺模型、损坏输入和脚本异常均可定位;
- Job/Pod TTL 清理后, 持久化结果仍可查看;
- 其他用户不能读取本任务预览或产物。